

神经正切核 (NTK) 简介及其推导

Hao Huang

March 2025

1 什么是 NTK ?

在现代机器学习研究中, **神经正切核(Neural Tangent Kernel, NTK)** 是一个重要的概念。它源自对神经网络优化过程的研究, 并与神经网络的梯度动态密切相关。本讲座将介绍 NTK 的基本概念, 并推导其数学形式。

2 神经网络的参数演化方程

神经网络的本质是一个 **参数化的函数**, 它接受输入 x , 经过网络变换后输出结果 $f(x)$ 。这个函数的具体形式由神经网络的参数 θ 决定, 因此我们可以将其记为:

$$f_{\theta}(x) \tag{1}$$

在优化过程中, 我们通常使用 **梯度下降法** 来更新神经网络的参数。最简单的梯度下降法定义如下:

$$\frac{d\theta}{dt} = -\eta \frac{\partial \mathcal{L}(f)}{\partial \theta} \tag{2}$$

其中, η 是学习率, $\mathcal{L}$ 是损失函数。下文将默认 $\eta = 1$ 以简化推导。

3 从参数空间到函数空间

既然参数 θ 随时间 t 变化, 函数 $f(x, \theta)$ 本身也会发生变化。我们关心的核心问题是: **函数 f 本身如何变化?**

利用链式法则，我们可以将其展开：

$$\frac{\partial f}{\partial t} = \sum_p \frac{\partial f}{\partial \theta_p} \cdot \frac{\partial \theta_p}{\partial t} \quad (3)$$

接下来我将介绍一下我自己的记号，后续推导都采用该记号，我觉得相比于原文的记号，它们可能更容易理解。

因为推导过程涉及张量求导，所以我们采用抽象指标记号（但是忽略协变指标与逆变指标的区别，统一在上标处写槽位）与爱因斯坦求和约定——如果一个指标重复两次就默认以它为下标进行求和——因此上式可以直接写成：

$$\frac{\partial f}{\partial t} = \frac{\partial f}{\partial \theta_p} \cdot \frac{\partial \theta_p}{\partial t} \quad (4)$$

对于一个向量 v ，把它的第 i 个分量记为 v^i 。类似的，如果把函数 f 视为一种无限维向量的话，那么 $f(x)$ 就可以写为 f^x ，而函数 $f(x)$ 本身取值往往是一个向量，而不是标量，因此函数 $f(x)$ 的第 i 个分量就记作 $f^{x,i}$ 。

因此有：

$$\frac{\partial f^{x,i}}{\partial t} = \frac{\partial f^{x,i}}{\partial \theta^p} \cdot \frac{\partial \theta^p}{\partial t} \quad (5)$$

注意到 $\frac{\partial \theta^p}{\partial t}$ 描述的正是参数的演化，代入参数演化方程，得到：

$$\frac{\partial f^{x,i}}{\partial t} = - \frac{\partial f^{x,i}}{\partial \theta^p} \cdot \frac{\partial \mathcal{L}(f)}{\partial \theta^p} \quad (6)$$

其中 $\frac{\partial \mathcal{L}(f)}{\partial \theta^p}$ 也可以用链式法则展开

$$\frac{\partial \mathcal{L}(f)}{\partial \theta^p} = \frac{\delta \mathcal{L}(f)}{\delta f^{x',i'}} \cdot \frac{\partial f^{x',i'}}{\partial \theta^p} \quad (7)$$

因此，神经网络的函数演化方程就是：

$$\frac{\partial f^{x,i}}{\partial t} = - \frac{\partial f^{x,i}}{\partial \theta^p} \cdot \frac{\delta \mathcal{L}(f)}{\delta f^{x',i'}} \cdot \frac{\partial f^{x',i'}}{\partial \theta^p} \quad (8)$$

调整顺序：

$$\frac{\partial f^{x,i}}{\partial t} = - \frac{\partial f^{x,i}}{\partial \theta^p} \cdot \frac{\partial f^{x',i'}}{\partial \theta^p} \cdot \frac{\delta \mathcal{L}(f)}{\delta f^{x',i'}} \quad (9)$$

我们发现乘积的三个项中只有前两个项涉及 θ ，这意味着只有它们才会受到神经网络权重的影响（一种权重本质上就是一种参数化的方式），而第三项完全是函数空间内的泛函导数，与你神经网络怎么实现是无关的。

因此，我们把前两项整体视为一个数学对象（一个由 x, x' 索引的 2D 张量，其中每个元素都是由 i, i' 索引的 2D 矩阵），称为“神经正切核”：

$$K^{i,i'}(x, x') := \frac{\partial f^{x,i}}{\partial \theta^p} \cdot \frac{\partial f^{x',i'}}{\partial \theta^p} \quad (10)$$

因此，神经网络的函数演化方程又可以写为：

$$\frac{\partial f^{x,i}}{\partial t} = -K^{i,i'}(x, x') \frac{\delta \mathcal{L}(f)}{\delta f^{x',i'}} \quad (11)$$

4 对神经正切核的一种感性认知


不妨想象一下，如果神经正切核是单位张量，会发生什么？这意味着只有在 $i = i', x = x'$ 时，才有 $K = 1$ ，否则 $K = 0$ 。此时

$$\frac{\partial f^{x,i}}{\partial t} = -\frac{\delta \mathcal{L}(f)}{\delta f^{x,i}} \quad (12)$$


换句话说，此时函数 f 的演化完全是沿着函数空间内的泛函梯度来的。

下面这幅图展示了一个典型的例子。假设初始函数是一条直线，在图中用虚线表示。而我们提供的训练样本位于 $X = 10$ 处，给出了对应的 Y 值。由于训练集中仅包含一个样本点，如果我们直接沿着函数空间的泛函梯度下降进行优化，会发现只有该样本点对应的函数值发生了变化，而其他位置的函数值保持不变。这种现象正是过拟合的典型表现。

为什么会这样呢？因为损失函数只由训练样本来定义，别的点处的扰动对损失函数是没有影响的，因此别的位置的泛函导数为零，函数值不发生变化。



而实际上我们的核函数并不是单位张量，因此它对周围的点也会产生一个连带的贡献。所以当我们把 $X = 10$ 位置的函数值往上推的时候，周围的点的函数值也会相应的发生变化，这就是泛化的现象。



5 中间层函数的演化

我们现在已经得到了神经网络的函数演化方程。不过，这里的“函数”指的是将输入映射到最终层输出的映射函数。除此之外，我们还可以考虑从输入到中间层输出的映射函数，研究中间层函数的演化方程。

我们定义网络函数为 $f_\theta(x) := f_L(x; \theta)$ ，其中，激活前函数 $f_l(\cdot; \theta) : \mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_l}$ 和激活后函数 $\alpha_l(\cdot; \theta) : \mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_l}$ 从第 0 层到第 L 层的定义如下：

$$\begin{aligned}\alpha_0(x; \theta) &= x \\ f_{(l+1)}(x; \theta) &= \frac{1}{\sqrt{n_l}} W_l \alpha_l(x; \theta) \\ \alpha_l(x; \theta) &= \sigma(f_l(x; \theta))\end{aligned}$$

其中，非线性函数 σ 是逐元素应用的。不失一般性，每层变换都忽略偏置项。初始化时， W_l^{ij} 均服从标准正态分布。

注意，与一般的神经网络相比，我们给每层线性变换都加上了 $O(n^{-\frac{1}{2}})$ 的缩放因子，这是很关键的参数化配置，又称为 NTK 参数化。




图 1: 神经网络示意图

之前我们得到的正是 f_L 的演化方程，那么中间层函数 f_{L-1} 如何演化？我们可以将神经网络的最后一层移入到损失函数中。

$$\mathcal{L}(f_L) = \mathcal{L}\left(\frac{1}{\sqrt{n_{L-1}}} W_{L-1} f_{L-1}\right) = \mathcal{L}^{new}(f_{L-1}) \quad (13)$$

$$\mathcal{L}^{new} := \mathcal{L} \circ W_{L-1} \quad (14)$$

这样实际上并未改变整个学习框架，只是以一种新的复合形式进行表达。然而，这样做会使我们的神经网络少一层。此时，在这个减少了一层的神经网络中，我们求解的输入到最后一层输出的映射函数，实际上就是原先神经网络中的中间层函数 f_{L-1} 。这是一种巧妙的转换方式。

根据这个少了一层的神经网络的函数演化方程：

$$\frac{\partial f_{L-1}^{x,i}}{\partial t} = -K_{L-1}^{i,i'}(x, x') \frac{\delta \mathcal{L}^{new}(f_{L-1})}{\delta f_{L-1}^{x',i'}} \quad (15)$$

链式展开泛函导数项：

$$\frac{\delta \mathcal{L}^{new}(f_{L-1})}{\delta f_{L-1}^{x',i'}} = \frac{\delta \mathcal{L}(f_L)}{\delta f_L^{x'',i''}} \cdot \frac{\partial f_L^{x'',i''}}{\partial f_{L-1}^{x',i'}} = \frac{W_{L-1}^{i'',i'} \dot{\sigma}(f_{L-1}^{x',i'})}{\sqrt{n_{L-1}}} \cdot \frac{\delta \mathcal{L}(f_L)}{\delta f_L^{x'',i''}} \quad (16)$$

因此：

$$\frac{\partial f_{L-1}^{x,i}}{\partial t} = -\frac{W_{L-1}^{i'',i'} \dot{\sigma}(f_{L-1}^{x',i'})}{\sqrt{n_{L-1}}} \cdot K_{L-1}^{i,i'}(x, x') \cdot \frac{\delta \mathcal{L}(f_L)}{\delta f_L^{x'',i''}} \quad (17)$$

利用张量版本的柯西不等式进行放缩：

$$\frac{\partial \|f_{L-1}^{*,i}\|_{\mathcal{D}}}{\partial t} \leq \left\| \frac{\partial f_{L-1}^{*,i}}{\partial t} \right\|_{\mathcal{D}} \quad (18)$$

$$\leq \frac{1}{\sqrt{n_{L-1}}} \|K_{L-1}\|_{op} \|\dot{\sigma}(f_{L-1}^{*,i})\|_{\infty} \|W_{L-1}^{*,i}\|_2 \left\| \frac{\delta \mathcal{L}(f_L)}{\delta f_L} \right\|_{\mathcal{D}} \quad (19)$$

其中， $\langle f, g \rangle_{\mathcal{D}} := \frac{1}{N} \sum_{i=1}^N f(x_i)^{\top} g(x_i)$ ，表示在输入分布上的内积， x_i 是输入样本，共 N 个。 $\|f\|_{\mathcal{D}} := \sqrt{\langle f, f \rangle_{\mathcal{D}}}$ 。

中间层函数的变化率 $\frac{\partial \|f_{L-1}^{*,i}\|_{\mathcal{D}}}{\partial t}$ 受到了同层线性变换权重 $\|W_{L-1}^{*,i}\|_2$ 的约束，而这个线性变换权重本身也会变化，它的变化率受到哪些因素的约束呢？

$$\frac{\partial W_{L-1}^{i,j}}{\partial t} = \frac{\partial W_{L-1}^{i,j}}{\partial \theta^p} \cdot \frac{\partial \theta^p}{\partial t} = -\frac{\partial W_{L-1}^{i,j}}{\partial \theta^p} \cdot \frac{\partial \mathcal{L}(f_L)}{\partial \theta^p} \quad (20)$$

$$= -\frac{\partial \mathcal{L}(f_L)}{\partial W_{L-1}^{i,j}} = -\frac{\delta \mathcal{L}(f_L)}{\delta f_L^{x,i}} \cdot \frac{\partial f_L^{x,i}}{\partial W_{L-1}^{i,j}} = -\frac{\sigma(f_{L-1}^{x,j})}{\sqrt{n_{L-1}}} \cdot \frac{\delta \mathcal{L}(f_L)}{\delta f_L^{x,i}} \quad (21)$$

因此：

$$\frac{\partial \|W_{L-1}^{*,j}\|_2}{\partial t} \leq \left\| \frac{\partial W_{L-1}^{*,j}}{\partial t} \right\|_2 \quad (22)$$

$$\leq \frac{1}{\sqrt{n_{L-1}}} \|\sigma(f_{L-1}^{*,j})\|_{\mathcal{D}} \left\| \frac{\delta \mathcal{L}(f_L)}{\delta f_L} \right\|_{\mathcal{D}} \quad (23)$$

这里之所以出现输入分布的范数，是因为损失函数是定义在输入分布上的，只有在输入样本上的扰动才能影响损失函数。

我们发现中间层函数变化率被线性变换权重约束，而线性变换权重本身的变化率又会被中间层函数约束。这个关系会在后面用到。

6 神经正切核的演化

神经正切核的原始论文主要贡献在于，他们证明了当神经网络的中间层宽度趋于无穷时，神经正切核 $K^{i,i'}(x, x'; \theta)$ 会收敛到一个固定的极限 $\Theta^{i,i'}(x, x')$ ，与参数 θ 无关了，而且这个极限核我们是可以直接算出来的。这个结论不仅在初始化时成立，在训练过程中也成立。

在一般情况下，神经网络训练的过程中，参数 θ 和函数 f 本身是同步演化的。参数 θ 的变化会导致核函数的变化，而核函数的变化又会进一步影响 f ，使得二者相互耦合。而固定极限核的结论意味着，当神经网络的宽度趋于无穷时，这种耦合被解除了，即函数 f 的演化与核函数 K 可以分离，函数演化方程变成线性 ODE。

定理 1. 对于层数为 L 的 NTK 参数化的神经网络，中间层神经元数 $n_1, \dots, n_{L-1}$ 依次趋于无穷大，则其输出函数 $f_L^{x,i}, i = 1, \dots, n_L$ 独立同分布，其分布收敛于方差为 Σ_L 的中心化高斯过程， Σ_L 递归定义如下：

$$\begin{aligned} \Sigma_1(x, x') &= \frac{1}{n_0} x^\top x' \\ \Sigma_{L+1}(x, x') &= \mathbb{E}_{f \sim \mathcal{N}(0, \Sigma_L)} [\sigma(f(x)) \sigma(f(x'))] \end{aligned}$$

证明. 我们通过归纳法证明这个结果。当 $L = 1$ 时，没有中间层：

$$f_1^i(x) = \frac{1}{\sqrt{n_0}} W_0^{ij} x^j$$

所有输出函数 $f_1^i(x)$ 因此是独立的，并且具有所需的协方差 Σ_1 。

归纳步骤的关键是将 $(L+1)$ -网络视为以下组合：一个 L -网络 $\mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_L}$ 将输入映射到中间层函数 $f_L^i(x)$ ，然后逐元素应用非线性函数 σ 和一

个随机线性映射 $\mathbb{R}^{n_L} \rightarrow \mathbb{R}^{n_{L+1}}$ 。归纳假设表明，在 $n_1, \dots, n_{L-1} \rightarrow \infty$ 下，中间层函数 $f_L^i(x)$ 独立同分布地趋向于具有协方差 Σ_L 的高斯过程。

因此在固定 $\sigma(f_L^j(x))$ 的值的条件下，输出函数

$$f_{L+1}^i(x) = \frac{1}{\sqrt{n_L}} W_L^{ij} \sigma(f_L^j(x))$$

是独立同分布的中心化高斯变量，其协方差为

$$\tilde{\Sigma}_{L+1}(x, x') = \frac{1}{n_L} \sigma(f_L^i(x)) \sigma(f_L^i(x'))$$

根据大数定律，当 $n_L \rightarrow \infty$ 时，这个协方差依概率收敛于期望值

$$\tilde{\Sigma}^{(L+1)}(x, x') \rightarrow \Sigma^{(L+1)}(x, x') = \mathbb{E}_{f \sim \mathcal{N}(0, \Sigma^{(L)})} [\sigma(f(x)) \sigma(f(x'))]$$

值得注意的是，协方差是确定性的，独立于 $\sigma(f_L)$ 。因此，在极限情况下，条件和无条件分布 $f_{L+1}^i(x)$ 是相等的：它们是具有协方差 Σ_{L+1} 的独立同分布的中心化高斯变量。 $\square$

定理 2. 对于层数为 L 的 NTK 参数化的神经网络，中间层神经元数 $n_1, \dots, n_{L-1}$ 依次趋于无穷大，则神经正切核 K_L 依概率收敛到一个确定性的极限核：

$$K_L \rightarrow \Theta_L := \Theta_L^{\text{scalar}} \otimes I_{n_L}.$$

$\Theta_L^{\text{scalar}} : \mathbb{R}^{n_0} \times \mathbb{R}^{n_0} \rightarrow \mathbb{R}$ 递归定义为：

$$\begin{aligned} \Theta_1^{\text{scalar}}(x, x') &= \Sigma_1(x, x') \\ \Theta_{L+1}^{\text{scalar}}(x, x') &= \dot{\Sigma}_{L+1}(x, x') \Theta_L^{\text{scalar}}(x, x') + \Sigma_{L+1}(x, x') \end{aligned}$$

其中

$$\dot{\Sigma}_{L+1}(x, x') = \mathbb{E}_{f \sim \mathcal{N}(0, \Sigma_L)} [\dot{\sigma}(f(x)) \dot{\sigma}(f(x'))]$$

对协方差为 Σ_L 的中心化高斯过程 f 取期望， $\dot{\sigma}$ 表示 σ 的导数。

证明. $L = 1$ 时：

$$K_1^{i,i'}(x, x') = \frac{x^j x'^j}{n_0} \cdot \delta^{ii'} = \Sigma_1(x, x') \cdot \delta^{ii'} \quad (24)$$

因此

$$\Theta_1^{\text{scalar}}(x, x') = \Sigma_1(x, x') \quad (25)$$

归纳步骤，相邻层的神经正切核之间满足如下关系：

$$\begin{aligned}
K_{L+1}^{i,i'}(x, x') &= \frac{\partial f_{L+1}^{x,i}}{\partial \theta^p} \cdot \frac{\partial f_{L+1}^{x',i'}}{\partial \theta^p} \\
&= \left(\frac{\partial f_{L+1}^{x,i}}{\partial f_L^{y,j}} \cdot \frac{\partial f_L^{y,j}}{\partial \theta^p} + \frac{\partial f_{L+1}^{x,i}}{\partial W_L^{i,j}} \cdot \frac{\partial W_L^{i,j}}{\partial \theta^p} \right) \cdot (\dots) \\
&= \frac{\partial f_{L+1}^{x,i}}{\partial f_L^{y,j}} \cdot \frac{\partial f_{L+1}^{x',i'}}{\partial f_L^{y',j'}} \cdot \frac{\partial f_L^{y,j}}{\partial \theta^p} \cdot \frac{\partial f_L^{y',j'}}{\partial \theta^p} + \frac{\partial f_{L+1}^{x,i}}{\partial W_L^{i,j}} \cdot \frac{\partial f_{L+1}^{x',i'}}{\partial W_L^{i',j'}} \cdot \frac{\partial W_L^{i,j}}{\partial \theta^p} \cdot \frac{\partial W_L^{i',j'}}{\partial \theta^p} \\
&\quad + \frac{\partial f_{L+1}^{x,i}}{\partial f_L^{y,j}} \cdot \frac{\partial f_{L+1}^{x',i'}}{\partial W_L^{i',j'}} \cdot \frac{\partial f_L^{y,j}}{\partial \theta^p} \cdot \frac{\partial W_L^{i',j'}}{\partial \theta^p} + \frac{\partial f_{L+1}^{x,i}}{\partial W_L^{i,j}} \cdot \frac{\partial f_{L+1}^{x',i'}}{\partial f_L^{y',j'}} \cdot \frac{\partial W_L^{i,j}}{\partial \theta^p} \cdot \frac{\partial f_L^{y',j'}}{\partial \theta^p}
\end{aligned}$$

前两项之和为：

$$\begin{aligned}
&= \frac{W_L^{ij} W_L^{i'j'} \dot{\sigma}(f_L^{x,j}) \dot{\sigma}(f_L^{x',j'})}{n_L} \cdot \frac{\partial f_L^{x,j}}{\partial \theta^p} \cdot \frac{\partial f_L^{x',j'}}{\partial \theta^p} + \frac{\partial f_{L+1}^{x,i}}{\partial W_L^{i,j}} \cdot \frac{\partial f_{L+1}^{x',i'}}{\partial W_L^{i',j'}} \cdot \delta^{ii'} \\
&= \frac{W_L^{ij} W_L^{i'j'} \dot{\sigma}(f_L^{x,j}) \dot{\sigma}(f_L^{x',j'})}{n_L} \cdot K_L^{j,j'}(x, x') + \frac{\sigma(f_L^{x,j}) \sigma(f_L^{x',j'})}{n_L} \cdot \delta^{ii'}
\end{aligned}$$

后两项之和为零，因为 θ_p 要么是 W_L 中的分量，要么是更前面的线性变换的分量，因此 $\frac{\partial f_L}{\partial \theta^p} \cdot \frac{\partial W_L}{\partial \theta^p}$ 总是有一项为零。因此有：


$$K_{L+1}^{i,i'}(x, x') = \frac{W_L^{ij} W_L^{i'j'} \dot{\sigma}(f_L^{x,j}) \dot{\sigma}(f_L^{x',j'})}{n_L} \cdot K_L^{j,j'}(x, x') + \frac{\sigma(f_L^{x,j}) \sigma(f_L^{x',j'})}{n_L} \cdot \delta^{ii'} \quad (26)$$

根据归纳假设，应用大数定律，以及 W_L^{ij} 服从标准正态分布的事实：

$$\Theta_{L+1}^{\text{scalar}}(x, x') = \dot{\Sigma}_{L+1}(x, x') \Theta_L^{\text{scalar}}(x, x') + \Sigma_{L+1}(x, x') \quad (27)$$

□

除了理论证明，我们可以做一个数值实验来验证上述定理，令 $L = 2, n_0 = 2, n_1 \rightarrow \infty, n_2 = 1$ ，此时对于固定的输入 x, x' ，神经正切核 $K(x, x')$ 就是一个 1×1 的矩阵，可以视为标量值，在不同中间层宽度下，多次初始化神经网络权重，计算该标量值，其箱线图的确显示神经正切核随着中间层数增大而趋于确定。



定理 3. 对于层数为 L 的 NTK 参数化的神经网络，其非线性激活函数 $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 满足 *Lipschitz* 连续、二阶可微、二阶导数有界，中间层神经元数 $n_1, \dots, n_{L-1}$ 依次趋于无穷大，则对于任何使得积分 $\int_0^T \|\frac{\delta \mathcal{L}(f_L)}{\delta f_L}\|_{\mathcal{D}} dt$ 有界的数值 T ，神经正切核 K_L 在时间区间 $[0, T]$ 上依概率一致收敛到一个确定性的极限核：

$$K_L(t) \rightarrow \Theta_L := \Theta_L^{scalar} \otimes I_{n_L}, \forall t \in [0, T]$$

作为结果，在这个极限下，输出函数 f 的动力学由以下微分方程描述

$$\frac{\partial f^{x,i}}{\partial t} = -\Theta^{i,i'}(x, x') \frac{\delta \mathcal{L}(f)}{\delta f^{x',i'}} \quad (28)$$

之前的定理是说初始化时神经正切核趋向于一个确定性的极限核，而这个定理是说训练过程中神经正切核也近乎保持不变。

先用一个简单的例子来介绍该定理的证明思想： $\frac{dy}{dx} = \frac{1}{\sqrt{n}}x \Rightarrow y = Ce^{n^{-\frac{1}{2}}x}$ 。当 $n \rightarrow \infty$ 时，这个函数的图像趋于一条水平的直线，也就是说 y 几乎不随 x 变化。

而根据上一节介绍的中间层函数的变化率与线性变换权重的变化率互相约束的关系， $\partial f \leq W, \partial W \leq f$ 。我们可以定义 $A := f + W$ 构造出不等式 $\partial A \leq A$ ，从而就转化为上面的例子，又由于我们的不等式右侧都是带

$\frac{1}{\sqrt{n}}$ 的, 因此只要让神经网络趋于无限宽, g 在固定时间区间内的变化量就可以趋于零。

既然中间层函数 f_{L-1} 与线性变换权重 W_{L-1} 在固定时间区间内的变化量趋于零, 而把神经正切核 K_L 的定义展开后就会发现它的变化量可以表示成中间层函数 f_{L-1} 与线性变换权重 W_{L-1} 的变化量, 因此也趋于零。

现在开始正式证明。

证明. 与之前的定理一样, 本证明采用网络层数的归纳法。当 $L = 1$ 时, 神经正切核不依赖于参数, 因此在训练过程中是恒定的。

对于归纳步骤, 我们将一个层数为 $L + 1$ 的网络拆分为一个层数为 L 、参数为 $\tilde{\theta}$ 的子网络, 以及一个线性变换 W_L 。较小的子网络遵循以下训练方向 (泛函梯度):

$$\frac{\delta \mathcal{L}^{new}(f_L)}{\delta f_L^{x,i}} = \frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}^{x',i'}} \cdot \frac{\partial f_{L+1}^{x',i'}}{\partial f_L^{x,i}} = \frac{W_L^{i',i} \dot{\sigma}(f_L^{x,i})}{\sqrt{n_L}} \cdot \frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}^{x',i'}} \quad (29)$$

我们现在希望将归纳假设应用于较小的子网络。为此, 我们需要证明当 $n_1, \dots, n_L \rightarrow \infty$ 时, $\int_0^T \left\| \frac{\delta \mathcal{L}^{new}(f_L)}{\delta f_L} \right\|_{\mathcal{D}} dt$ 是有界的。由于 σ 是一个 c -Lipschitz 函数, 我们有:

$$\left\| \frac{\delta \mathcal{L}^{new}(f_L)}{\delta f_L} \right\|_{\mathcal{D}} \leq c \frac{1}{\sqrt{n_L}} \|W_L\|_{op} \left\| \frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}} \right\|_{\mathcal{D}}$$

为了应用归纳假设, 我们现在需要对 $\left\| \frac{1}{\sqrt{n_L}} W_L(t) \right\|_{op}$ 进行界估计。根据引理 4, 我们只需要限制住 $\left\| \frac{1}{\sqrt{n_L}} W_L(0) \right\|_{op}$ 。根据大数定律, $W_L(0)$ 的每个行向量的 L_2 范数都是有界的——注意 $W_L(0)$ 一共有 n_{L+1} 行, n_{L+1} 是最后一层的神经元数, 它是有限的, 不趋于无穷——用该矩阵变换后的向量的每个分量因此都有界, 所以 $\|W_L(0)\|_{op}$ 有界。

现在我们可以对子网络应用归纳假设, 再根据之前一节提过的中间层函数变化率与线性变换权重变化率的互相制约的关系:

$$\frac{\partial \|f_L^{*,i}\|_{\mathcal{D}}}{\partial t} \leq \frac{1}{\sqrt{n_L}} \|\Theta_L^{\text{scalar}}\|_{op} \|\dot{\sigma}(f_L^{*,i})\|_{\infty} \|W_L^{*,i}\|_2 \left\| \frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}} \right\|_{\mathcal{D}} \quad (30)$$

$$\frac{\partial \|W_L^{*,i}\|_2}{\partial t} \leq \frac{1}{\sqrt{n_L}} \|\sigma(f_L^{*,i})\|_{\mathcal{D}} \left\| \frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}} \right\|_{\mathcal{D}} \quad (31)$$

我们令 $A(t) = \|f_L^{*,i}(t)\|_{\mathcal{D}} + \|W_L^{*,i}(t)\|_2$, 则有

$$\frac{\partial A(t)}{\partial t} \leq \frac{\max\{c\|\Theta_L^{\text{scalar}}\|_{op}, 1\}}{\sqrt{n_L}} \left\| \frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}} \right\|_{\mathcal{D}} A(t) \quad (32)$$

$$A(t) \leq A(0) \exp\left(\frac{\max\{c\|\Theta_L^{\text{scalar}}\|_{op}, 1\}}{\sqrt{n_L}} \int_0^T \left\| \frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}} \right\|_{\mathcal{D}} dt\right) \quad (33)$$

由于泛函梯度 $\frac{\delta \mathcal{L}(f_{L+1})}{\delta f_{L+1}}$ 在 $[0, T]$ 上的积分是有界的 (这个积分结果是一个随机变量, 这里的有界是指随机有界), 因此当 $n_L \rightarrow \infty$ 时, $\|f_L^{*,i}(t)\|_{\mathcal{D}}$ 与 $\|W_L^{*,i}(t)\|_2$ 以 $O(\frac{1}{\sqrt{n_L}})$ 的速率趋于零。

我们可以利用这些界来控制神经正切核的变化。为了理解核的演化, 我们需要研究函数对参数的导数的变化情况。

把参数分为两部分, 第一部分是最后一层线性变换的权重:

$$\frac{\partial f_{L+1}^{x,i}}{\partial W_L^{ij}} = \frac{1}{\sqrt{n_L}} \sigma(f_L^{x,j})$$

已知 $f_L^{x,j}$ 以速率 $\frac{1}{\sqrt{n_L}}$ 演化, 因此神经正切核的项 $\frac{\partial f_{L+1}^{x,i}}{\partial W_L^{ij}} \otimes \frac{\partial f_{L+1}^{x,i}}{\partial W_L^{ij}}$ 以 $n_L^{-\frac{3}{2}}$ 的速率演化¹, n_L 个 j 求和, 从而导致神经正切核的变化速率为 $\frac{1}{\sqrt{n_L}}$ 。

第二部分是更前面层的线性变换权重:

$$\frac{\partial f_{L+1}^{x,i}}{\partial \theta^p} = \frac{1}{\sqrt{n_L}} W_L^{ij} \dot{\sigma}(f_L^{x,j}) \frac{\partial f_L^{x,j}}{\partial \theta^p}$$

它们对神经正切核 $\Theta_{L+1}^{i,i'}(x, x')$ 的贡献为:

$$\frac{1}{n_L} \Theta_L^{jj'}(x, x') \dot{\sigma}(f_L^{x,j}) \dot{\sigma}(f_L^{x',j'}) W_L^{ij} W_L^{i'j'}$$

根据归纳假设, 较小网络的神经正切核 Θ_L 在 $n_1, \dots, n_{L-1} \rightarrow \infty$ 的情况下对角线部分趋于 Θ_L^{scalar} , 其余部分趋于零。因此, 其贡献变为:

$$\frac{1}{n_L} \Theta_L^{\text{scalar}}(x, x') \dot{\sigma}(f_L^{x,j}) \dot{\sigma}(f_L^{x',j}) W_L^{ij} W_L^{i'j}$$

连接权重 W_L^{ij} 以速率 $\frac{1}{\sqrt{n_L}}$ 变化, 因此整个和的变化率也为 $\frac{1}{\sqrt{n_L}}$ 。我们只需要证明 $\dot{\sigma}(f_L^{x,j})$ 也以速率 $\frac{1}{\sqrt{n_L}}$ 变化。由于 σ 的二阶导数是有界的, 我们有:

$$\frac{\partial \dot{\sigma}(f_L^{x,j})}{\partial t} = O\left(\frac{\partial f_L^{x,j}}{\partial t}\right) = O\left(\frac{1}{\sqrt{n_L}}\right)$$

因此整个神经正切核的变化率为 $\frac{1}{\sqrt{n_L}} \rightarrow 0$, 这完成了证明。 $\square$

¹如果 u, v 本身是 $O(\frac{1}{\sqrt{n}})$, 变化率 du, dv 是 $O(\frac{1}{n})$, 则 $d(uv) = u dv + v du$ 是 $O(n^{-\frac{3}{2}})$

引理 4. 在定理 3 的设定下, 对于 $L+1$ 层的网络, 对于任意 $\ell = 1, \dots, L$, 我们有概率意义上的收敛性:

$$\lim_{n_L \rightarrow \infty} \cdots \lim_{n_1 \rightarrow \infty} \sup_{t \in [0, T]} \left\| \frac{1}{\sqrt{n_\ell}} (W_\ell(t) - W_\ell(0)) \right\|_{op} = 0.$$

这个引理的证明思路与定理 3 中设 A 的思路类似, 在此省略。

7 反直觉现象

令人意想不到的是, 即使中间层函数几乎保持不变, 最终层函数仍可能发生显著变化, 从而表明网络确实在学习, 而不是整体近乎静止——那样就是 trivial 的现象了, 不值得研究。实际上 NTK 的后续工作有人提出 abc 参数化, 就是把线性变换、初始分布、学习率都加上了缩放因子, 根据缩放因子的幂指数的组合划分了不同的情况, 一些是 trivial 的, 一些是 NTK 的, 一些则是 feature learning 的。换句话说, NTK 参数化的缩放因子 $O(n^{-\frac{1}{2}})$ 的 $\frac{1}{2}$ 取得好, 使得神经正切核的变化量趋于零, 但是神经正切核本身趋于一个非零核, 如果把指数 $-\frac{1}{2}$ 改成 $-1, -2$ 这样子就会导致神经正切核本身趋于零, 整个网络训练趋于静止。

那么为什么中间层函数近似不变, 但网络依然能进行学习呢? 因为最终层函数的变化被无穷多个中间层分量均摊后就变得稀薄了, 有点类似调和级数每一项都趋于零, 但是总和发散。

我觉得 NTK 本质上是一种重参数化的方法, 它将原本复杂的非线性优化问题转化为一个基于核函数的线性动力学问题。

8 NTK 的应用案例

推导了那么多, 那么 NTK 到底怎么作为理论工具用于具体问题的分析呢?

比如 Analyzing Monotonic Linear Interpolation in Neural Network Loss Landscapes 这篇论文用 NTK 研究了神经网络的单调线性插值 (MLI) 性质 (但我还没仔细看过这篇论文, 只知道它在附录里的确用了 NTK 做理论证明)。

我觉得 NTK 作为理论工具, 它的一个用法是, 当你想证明一般的神经网络上的结论时, 但你又证明不了, 那么你就可以把一般的神经网络假装成

NTK 网络（用 NTK 参数化且宽度趋于无穷的这类特殊的神经网络），在这个设置下证明你的结论，然后一般的神经网络你就做一下数值实验就行了，这样既有理论分析，又有实验证据。

也就是说，NTK 可以作为一般神经网络的代替品，因为它本身也就是一个神经网络，只不过特殊了一点，比如无限宽，但是无限宽比较不关键，因为我们可以用较大的有限宽度近似，而 NTK 参数化也只不过是权重上加了缩放系数。可以说，一般神经网络该有的特性它基本都有，比如逐层线性变换加激活函数，比如能拟合非线性的复杂函数；一般神经网络不具备的好的特性它也有，比如它的极限核可以直接显式地计算出来，比如它的极限核在某些损失函数条件下是正定的，这意味着收敛性是有保证的。

但是有一个重要的现象，NTK 刻画不了，那就是“特征学习”。

9 特征学习

这一节是题外话，我们知道 NTK 参数化下，神经网络的中间层函数是近似不变的，也就是说，它是无法刻画特征学习的，而实际的神经网络的特征学习是很重要的现象，比如机制可解释性的大部分研究都依赖于“神经网络能学到特征”这一前提。已经有人提出一种新的参数化可以刻画特征学习，这部分我还在学习中，所以只能在这里稍微提一提。